因果推断 · 前四讲学习笔记

从相关走向因果 · 阅读批注版

先想清楚
没有它会怎样

绪论 · 潜在结果 · 随机试验 · 匹配与加权

> **贯穿全书的问题**
> 做了某件事的人结果更好，究竟是这件事有用，还是这些人本来就不同？

本笔记按“提出问题 → 定义反事实 → 找到识别条件 → 选择估计方法 → 检查结论”的顺序重组课程内容。公式配有直觉解释，案例与上传数据对应，容易混淆的地方单独说明。

使用方式：第一遍理解主线；第二遍遮住答案做手算；第三遍把右栏写成自己的例子。公式中的条件，比公式的外形更重要。

版式：A4 单页阅读；每页右侧留有批注栏；正文可检索、复制和高亮。PDF 目录与书签可用于跳转。

版本：2026 年 10 月 23 日。适用范围为目前收到的前四讲，后续章节只作衔接预告。

批 注

我最想回答的因果问题是什么？

目录与建议阅读顺序

课程地图与材料 03

符号表 04

绪论：相关、识别与三个错觉 05

ESG：代码、数据与显著性 08

潜在结果：定义、参数与分解 12

随机试验：设计、检验与边界 18

DAG：控制、中介与对撞 25

匹配与加权：条件、方法、诊断 27

NSW–CPS 与 PSM–DID 应用 35

手算、辨析与复习路线 37

大作业要求与研究设计模板 40

来源与复核范围 42

三种读法

从头学习：按目录顺序；每次读 4—6 页，完成一处手算或写一句自己的解释。

考前复习：先看第 4 页符号表，再看第 15—16 页分解、第 18 页随机化、第 27 页观察研究条件、第 33—34 页加权与双重稳健。

准备大作业：先读第 40—41 页要求与研究模板，再回到方法页。选题之后应先定义目标量和识别假设，再考虑软件命令。

> 批注建议：用一种颜色标“定义”，一种颜色标“假设”，一种颜色标“尚未解决的疑问”。不要把三者画成同一种重点。

批 注

我的理解 / 疑问 / 补充例子

全课地图：缺的那一半，从哪里来？

一条递进的主线

第一讲：提出困境。 相关、显著性、拟合优度，都不能自行证明“如果改变处理，结果会怎样”。

第二讲：把困境写成公式。 定义两个潜在结果与平均效应；把观测差拆成目标效应和偏差。

第三讲：设计一个可信的比较。 随机分配让组别不携带潜在结果信息，以设计保证可比性。

第四讲：没有随机分配时怎么办？ 在明确假设下，用可观测特征构造比较对象，并诊断重叠、平衡与规格敏感性。

方法	反事实信息从哪里借?	关键依据
随机试验 RCT	随机分配到另一组的人	已知分配机制
回归 / 匹配 / IPW	相关特征可比的另一组	非混杂性与重叠
双重差分 DID	对照组的结果变化	未处理潜在结果的平行趋势
断点回归 RD	门槛另一侧附近的人	门槛处连续性等条件
合成控制	其他未处理地区的加权组合	合适的拟合与结构条件

材料对应：第一讲 PPT 40 页；第二讲 PDF 62 页；第三讲 PDF 65 页；第四讲 PDF 81 页，位于 ZIP 内。另有 ESG Notebook 与 CSV，以及 NSW / CPS 两份 DTA 数据。

缩写提醒：SCM 有时指结构因果模型，有时指合成控制法；看上下文，不要当成同一种方法。

批 注

每一种方法，都在拿什么换取可比性？

符号表：把下标、条件与帽子读明白

记号	中文含义	培训例子
i	观测单位	第 i 位劳动者
$D_i \in \{0,1\}$	实际处理状态	是否接受培训
Z_i	随机分配的资格或邀请	是否抽中培训资格
$Y_i(1)$	接受处理时的潜在结果	若培训，结果时点收入
$Y_i(0)$	未接受处理时的潜在结果	若不培训，同一时点收入
Y_i	实际观测结果	实际测到的收入
X_i	前定协变量	年龄、教育、历史收入
τ_i	个体因果效应	$Y_i(1) - Y_i(0)$
$e(X)$	倾向得分	给定特征后的处理概率
$m_d(X)$	结果条件均值函数	$E[Y \mid D=d, X]$
N_1, N_0	两组样本量	处理 / 对照人数
p	总体处理占比	$P(D=1)$

三个读公式的习惯

竖线 | 读“给定 / 在……之中”。$E[Y \mid D=1]$ 是处理组的平均观测结果。

帽子 $\hat{}$ 表示估计值。$e(X)$ 是真实概率，$\hat{e}(X)$ 是用数据估出来的概率。

$\perp$ 与 $\mid X$：$D \perp Y(0)$ 是无条件独立；$D \perp Y(0) \mid X$ 是给定 X 后独立。二者不能互换。

> **最常见的误读**：$Y(0)$ 不是处理前的结果；ATT 不是处理组结果均值；$e(X)$ 不是处理效应。

批 注

用自己的研究题目替换右栏例子。

三种问题，三种答案

1．描述：这批数据长什么样？

“ESG 高的公司，下一年收益是不是也高？”描述不同公司之间的关系，可以算相关、均值差或回归斜率。

2．预测：新样本能不能猜准？

“能不能用 ESG 预测下一年收益？”要看样本外表现。一个变量不是原因，也可能有预测价值：雨伞销量可以帮助判断下雨，但多卖雨伞不会使天空下雨。

3．因果：主动改变后会怎样？

“让同一家公司提高 ESG，会使收益提高多少？”必须说明提高 ESG 的具体动作，并比较做与不做时的潜在结果。

层次	核心评价问题
识别	这个可观测比较，凭什么对应目标因果量？
估计	用什么统计量或算法算这个量？
推断	估计的不确定性有多大？
外推	对其他人群、时间和规模是否适用？

研究设计的六步

提出具体因果问题 → 写明目标量与识别假设 → 选择估计策略 → 做适当诊断与稳健性分析 → 研究机制和异质性 → 讨论解释范围与外推。

> 显著性主要回答不确定性问题。它不能替你证明比较对象可比。识别顺序应在模型选择之前。

批 注

把“有关”改写成一个具体干预问题。

OLS：什么时候斜率才是因果效应？

回归先给出一种线性关系

带截距的一元 OLS 斜率为：

$$\widehat{\beta} = \frac{\widehat{\mathrm{Cov}}(X, Y)}{\widehat{\mathrm{Var}}(X)}.$$

它衡量 X 相差一个单位时，Y 在线性拟合意义上对应多大差异。最佳线性拟合不一定等于真实条件均值曲线。

把其他影响因素写出来

若一个恰当定义的结构模型为：

$$Y = \alpha + \tau X + U,$$

则总体回归斜率满足：

$$\beta = \tau + \frac{\mathrm{Cov}(X, U)}{\mathrm{Var}(X)}.$$

τ 是该模型中的因果参数；U 汇集其他影响结果的因素。只要 X 与这些因素有关，斜率就会混入它们的作用。将其解释为因果还需要模型、干预和识别条件成立。

例子：名校毕业生收入高，可能既有学校的教育与人脉作用，也有入学前的能力和家庭背景差异。

为什么大样本和高 R^2 不能修好它？

大样本通常缩小抽样波动，却不会自动消除遗漏混杂。R^2 衡量拟合程度，不能证明箭头方向。

> **准确表述**：单靠回归运算不能确立因果；在可信设计和假设下，回归可以用来估计因果效应。

批 注

谁同时影响了处理选择与结果？

三个错觉：数据怎样误导因果判断？

伪回归：共同变动未必有经济联系

两条独立随机游走：

$$X_t = X_{t-1} + u_t, \qquad Y_t = Y_{t-1} + v_t.$$

即使创新独立，水平回归也可能产生高 R^2 与显著 t 值。非平稳序列的持久波动会破坏常规推断条件，不一定需要共享一条确定性趋势。

向均值回归：极端后的改善未必是疗效

把一次成绩写成“稳定能力＋偶然因素”。这次特别差的人，可能部分因为坏运气；下一次即使没有补课，也可能恢复。

因此，“补课后减去补课前”混合了补课、坏运气消退，以及其他时间变化。改善可以来自干预，也可以来自自然过程。

选择性比较：看到的人经过了筛选

处理选择：主动报名培训者可能更积极，也可能更缺工作。决定方向的是具体成本与报名机制。

样本选择：成功减肥的人更愿意分享，失败者没有出现在故事里；只看存活基金也会改变样本构成。

警报信号	下一步应追问
两个序列一起涨	是否非平稳？联系来自哪里？
极端者干预后改善	没干预时也会恢复吗？
接受者比未接受者好	是谁选择接受？本来会怎样？
只看到成功者	谁被筛掉了？筛选受什么影响？

> “相关不等于因果”是一项诊断起点。更有用的工作是指认哪条路径让比较失真。

批 注

我的理解 / 疑问 / 补充例子

读懂数据与抽样波动

一行是什么？五列是什么？

这是老师生成的模拟数据，共 600 家公司，五个行业各 120 家。

列	含义
industry	银行、地产、医药、科技、消费
size / growth	标准化规模 / 成长性
esg	标准化 ESG 得分
ret_next	下一年收益变量

`df.shape` 返回行列数；`df['size']` 才是规模列。`df.size` 是总元素数，这里是 3000。

同样的回归，不同的 120 家

```
sub = df.sample(n=120, random_state=101)
m = smf.ols('ret_next ~ esg', sub).fit()
```

随机种子	ESG 系数	p 值
101	0.1411	0.1121
202	0.1368	0.1378
303	0.2378	0.0031
404	0.1593	0.0717
505	0.1309	0.1208

已复核：数字来自上传 CSV 的重算。各次随机抽样可能互相重叠，并非将 600 家分成五个互斥小组。

> 只有第三组达到 5% 显著。显著与否会受抽样影响，不能把“一组显著、另一组不显著”直接当成两组效应有显著差异。

批 注

改变样本量，波动会怎样变化？

控制变量：为什么符号会翻转？

全样本看起来很明确

600 家全部使用，一元回归得到：

$$\widehat{\beta}_{ESG} = 0.1549, \qquad p \approx 0.000083.$$

95% 置信区间约为 $[0.0781,\ 0.2316]$；$R^2 \approx 0.0256$。

然后逐步加入前定特征

模型	ESG 系数	p 值	R^2
只放 ESG	0.1549	0.000083	0.0256
＋规模	−0.0822	0.0603	0.1597
＋规模、成长性	−0.0278	0.5554	0.1720
＋规模、成长性、行业	−0.0210	0.6494	0.2174

```
'ret_next ~ esg + size + growth + C(industry)'
```

`C(industry)` 表示按类别加入行业虚拟变量。它是模型表达方式，本身不提供因果识别。

变化意味着什么？

规模与 ESG 有关，又影响收益。未加入规模时，ESG 的斜率混入了规模信息。调整后是在更可比的背景下描述 ESG 与收益的关系。

最后一个模型的 ESG 95% 区间约为：

$$[-0.1115,\ 0.0695].$$

它包含零，说明证据不足以拒绝零系数；并不等于数据证明效应严格为零。也不能仅因加控制后变得不显著，就断言所有混杂已消除。

批 注

系数变化揭示了什么？还不能证明什么？

揭开生成机制：显著相关，真效应为零

老师知道“真相”，因为数据是他生成的

用 $z(\cdot)$ 表示标准化，生成逻辑是：

$$ESG = z(0.55\,size + 0.35\,growth + \varepsilon).$$
$$ret = 0.10 + 0.40\,size - 0.10\,growth + 0.30\,I + 0.90\,\varepsilon'.$$

I 为行业层面的生成项。收益方程没有 ESG；这个生成机制中也没有 ESG 进一步改变规模或成长性的路径。因此设定的 ESG 因果效应为零。

行业 → 规模 → ESG

行业 → 成长性 → ESG

规模 → 收益　　成长性 → 收益

行业 → 收益

一条关键的非因果路径是：

$$ESG\leftarrow规模\rightarrow收益.$$

ESG 携带了规模信息，规模又影响收益，所以“ESG 高的公司收益较高”完全可以在 ESG 无因果作用时出现。

为什么现实研究更难？

真实数据没有生成者把方程摊开给你看。你要用制度知识、研究设计、理论和敏感性分析，论证哪些比较可解释为干预效应。

> 本例知道真效应为零，依据是设定的生成机制。最后一个模型不显著，只是与零效应相容，二者的逻辑来源不同。

单位提醒：标准化 ESG 增加 1，是增加一个标准差。收益的单位应以数据定义为准；不要在未确认编码时自行把系数改写为百分比。

批 注

我的理解 / 疑问 / 补充例子

p 值、置信区间与研究者自由度

p 值回答什么?

在给定零假设及统计模型条件下，得到至少和观测结果同样极端统计量的概率。它不是“零假设为真的概率”，也不是“结果由运气造成的概率”。

不显著不等于无效；可能是真效应小，也可能是噪声大或样本少。要结合点估计、区间和实质意义。

95% 置信区间怎样读?

在相应条件下反复抽样并构造区间，这种方法约有 95% 的区间覆盖固定真参数。单次区间给出与数据及模型相容的一组参数范围；不能忽略模型与识别条件。

为什么要分行业再跑一次?

附件的一元行业回归中，银行、科技、消费达到 5% 显著，但设定中的 ESG 因果效应仍为零。行业内依然可能有规模等混杂。

如果看完结果只报告显著行业，便把分析选择变成了选择性报告。样本、时间段、控制变量和函数形式都可能成为岔路。

一份更完整的结果说明

“在预先说明的样本和模型下，ESG 系数为……，区间为……。该结果是条件相关；因果解释需要……假设。我们报告全部预定规格及合理敏感性结果。”

动手练习：把样本量改成 60、120、240，进行多次重复抽样，比较斜率分布，而非只换一个种子看一次结果。

> 单纯多试几个规格不一定有错；问题在于隐藏选择过程、只留下好看的答案。

批 注

我的理解 / 疑问 / 补充例子

两个世界：效应是一个差

先定义处理与结果时点

$D_i = 1$：接受一项明确版本的培训；$D_i = 0$：不接受该项培训。结果是培训结束一年后的收入。

$Y_i(1)$：这个人若接受培训，该时点会有的收入。
$Y_i(0)$：这个人若不接受培训，同一时点会有的收入。

$$\tau_i = Y_i(1) - Y_i(0).$$

假设教学例子中两者分别为 8 万、6 万，那么培训对他的效应是增加 2 万。8 万是结果水平，不是因果效应。

观测结果是一个开关

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0).$$

$D_i = 1$ 时留下 $Y_i(1)$；$D_i = 0$ 时留下 $Y_i(0)$。这个一致性关系把观察数据与潜在结果连接起来，依赖处理被恰当定义。

实际状态	看得到	看不到
接受培训	$Y_i(1)$	$Y_i(0)$
未接受培训	$Y_i(0)$	$Y_i(1)$

三个边界

同一个体：不同人的差不自动等于个体效应。
同一结果时点：培训前收入不等于未培训潜在结果。
明确处理版本：提高 ESG、接受教育、参加项目都应细化为可描述的干预。

> 可操纵干预是定义问题的有用准则；不能简单理解成“无法亲自随机改变的属性，一概不能研究因果”。通常应改写为清晰的政策、信号或待遇干预。

批 注

写出你自己的 D、Y(1)、Y(0) 与结果时点。

根本问题与 SUTVA：能比的前提

为什么再多数据也不能直接看见个人反事实？

同一个人在同一情境和结果时点，只实际经历一种处理状态。这是结构性缺失，不是忘记测量。

前后各测一次也不自动解决：时间在变，前一次处理可能留下痕迹。反复测量或面板数据能提供额外信息，但需要相应设计与假设。

SUTVA 的两个部分

无干扰：我的潜在结果不因别人的处理而改变。若存在传播、竞争或同伴影响，应考虑 $Y_i\left(d_i, d_{-i}\right)$。

无相关的隐藏处理版本：同样标为 $D=1$ 的干预，要足够明确。一小时视频、半年面授、半年面授加就业推荐，不能不加区分地当成相同处理。

违反时怎么办？

可扩大随机化单位、显式估计溢出，或把目标改为整个群体的政策效应。扩大单位后仍要论证跨单位干扰足够小。

场景	比较可能怎样改变？
驱虫或疫苗改善附近对照健康	组间差可能缩小
补贴企业抢走对照企业订单	组间差可能扩大
全国推广引发价格和竞争变化	小规模效应可能无法直接外推

相关不等于干扰：同班两人成绩接近，不一定违反无干扰；一个人的处理改变另一个人的结果，才是这里关注的结构。

> 讨论高估或低估时，要先说明相对于哪一种直接效应、总效应或政策效应。

批 注

我的理解 / 疑问 / 补充例子

ATE、ATT、ATU：先问对谁平均

$$ATE = E[Y(1) - Y(0)]$$
$$ATT = E[Y(1) - Y(0) \mid D = 1]$$
$$ATU = E[Y(1) - Y(0) \mid D = 0]$$

ATU 也常写作 ATC。三者平均的是同一种个体效应，只是目标人群不同。

政策问题	对应量
实际参加者因项目受益多少?	ATT
尚未参加者若加入，会受益多少?	ATU
目标总体中所有人的平均效应?	ATE

设 $p = P(D = 1)$，由全期望公式：

$$ATE = pATT + (1 - p)\,ATU.$$

例：20% 参与者平均受益 5，未参与者若参加平均受益 1，则总体平均为 $0.2 \times 5 + 0.8 \times 1 = 1.8$。

试点不等于推广

试点可能挑了最有能力执行的地区，也可能挑了最困难地区。试点 ATT 与其他地区 ATU 不必相同。规模变化还可能改变处理版本和市场环境。

取消补贴：先确定计量口径

若只把原处理组从 1 改为 0，并假定无额外动态与干扰，原处理组平均变化为 $-ATT$；总体平均变化为 $-pATT$；总体总量变化为 $-N_1 ATT$。

> ATT 不是处理组收入均值。ATT 仍包含处理组未处理时的反事实，不能直接从处理组一列结果读出来。

批 注

你的决策问题要 ATE、ATT，还是 ATU?

两分解与三分解：把偏差指认出来

第一步：写下能观察的差

$$SDO = E[Y|D=1] - E[Y|D=0]$$
$$= E[Y(1) \mid D=1] - E[Y(0) \mid D=0].$$

第二步：加减同一个反事实均值

加上再减去 $E[Y(0) \mid D=1]$，得到：

$$SDO = ATT + B,$$

其中：

$$B = E[Y(0) \mid D=1] - E[Y(0) \mid D=0].$$

B 的含义：**若两组都不接受处理，本来会差多少？** 这是本章特定定义的选择偏差。

第三步：目标换成 ATE

由恒等式：

$$ATT - ATE = (1-p)(ATT - ATU),$$

可得：

$$SDO = ATE + B + (1-p)(ATT - ATU).$$

缺口	包含什么？
$SDO - ATT$	选择偏差 B
$SDO - ATE$	B 加平均效应异质性带来的差异

不能把 $SDO - ATE$ 全叫作本章的选择偏差，除非相关异质性项恰好为零。

> 这些是总体量之间的恒等关系。样本中的均值差还会有抽样或随机分配波动。写下偏差公式，不表示已经知道偏差大小。

批 注

用一句话读出 B，不能只读符号。

手算案例：六个县的一笔账

县	D	$Y(1)$	$Y(0)$	τ	观测 Y
A	1	15	9	6	15
B	1	12	8	4	12
C	1	12	10	2	12
D	0	10	8	2	8
E	0	8	6	2	6
F	0	9	7	2	7

先算三个真实效应

$$ATT = (6+4+2)/3 = 4,$$
$$ATU = (2+2+2)/3 = 2,$$
$$ATE = (6+4+2+2+2+2)/6 = 3.$$

再只看“亮着”的观测列

$$SDO = (15+12+12)/3 - (8+6+7)/3 = 13 - 7 = 6.$$

选择偏差：

$$B = (9+8+10)/3 - (8+6+7)/3 = 9 - 7 = 2.$$

两分解：$6 = 4 + 2$。三分解：$6 = 3 + 2 + 0.5(4-2)$。

解释：观测差高于 ATT，是因为被扶持县即使不被扶持也高 2；高于 ATE 的另一部分，是被扶持县受益更多。

> 现实中处理组的 $Y(0)$ 看不见。这个教学表能算出 B，正因为它额外给了现实没有的反事实。

批 注

遮住解答，重算五个量并验证两条分解。

偏差的方向，从分配机制里找

判断方向的两个问题

1. 谁更容易进入处理组?
2. 这些人如果没接受处理，在结果时点会怎样?

情形	对 B 的合理推测
审批优先给基础好、配套强的企业	在这些条件确实预示较高 $Y(0)$ 时，$B>0$
培训主要面向长期失业者	若未处理收入更低，$B<0$
自愿报名，但成本结构未知	方向不能仅由“自愿”决定

选择偏差与受益异质性是两回事

“本来更好”说的是 $Y(0)$；“更能从政策获益”说的是 $Y(1)-Y(0)$。基础好的地方未必受益更大，基础差的地方也未必有更大提升空间，需要机制论证。

如果 $B<0$、异质性项 >0，两个误差可能部分抵消。因此某个数字碰巧接近目标，并不能证明识别可靠。

医疗试点题的谨慎读法

课件把争取来的试点与指定困难县作比较，意在练习方向判断。其答案建立在“基础映射到未处理结果、并影响政策收益”等机制判断上，不是只由题面标签必然推出。

此外，“试点指标前后改善了 X”是变化量，不能直接把它当成处理与对照的同期 SDO；还缺少没有政策时本来会怎样变化的信息。

> 将识别假设写成可讨论的机制，比在题目旁机械填一个正负号更重要。

批 注

我的理解 / 疑问 / 补充例子

随机化为什么能识别平均效应?

把分组交给已知随机程序

适当的随机分配使:

$$D \perp (Y(1), Y(0)).$$

组别不再携带“这个人本来会怎样”的信息。由一致性与独立性:

$$\begin{aligned} E[Y \mid D=1] - E[Y \mid D=0] &= E[Y(1)] - E[Y(0)] \\ &= ATE. \end{aligned}$$

无偏不等于这次精确命中

固定一批实验单位并反复按设计抽签，均值差估计量的期望等于样本平均处理效应。任何一次抽签仍可能产生协变量差异和估计误差。

平衡的是系统性的分配关系

随机化使已知、未知的前定因素都不系统性决定组别；它不承诺每次抽签年龄、收入、能力都逐项相同。

两个不同的随机动作	主要解决什么?
从目标总体随机抽样	样本代表性与总体推断
在实验样本内随机分组	组间可比性与内部识别

在一所学校志愿者中随机分组，可以内部可信，但不能自动代表所有成年人。

> 随机化不能自动处理分配后发生的流失、不遵守和干扰，也不自动把非随机招募样本变成总体随机样本。

批 注

平衡为何是期望意义，而非逐项相等?

随机化怎样做：单位、规则与预先分析

设计	分配规则与适用情形
完全随机化	固定处理人数；从所有相应名单随机抽一份
伯努利随机化	每人独立按概率分组；总人数可能变化
分层随机化	按前定特征分层，再在层内随机
群组随机化	按班、校、村等单位随机，容纳组内干扰
鼓励设计	随机邀请、资格或补贴，推动实际处理
随机分批推进	资源有限时随机决定先后顺序

规则不同，推断也不同。 完全随机化不能重摇成任意人数；分层实验不能打乱层结构；群组实验应按群组处理随机性和相关性。

开跑前写清五件事

处理：具体动作、剂量、资格和执行方式。
结果：主要结果变量、测量方法与时间。
随机单位：人、班级、学校、企业还是地区。
前定变量：分配之前确定，避免看结果后挑选。
分析规则：主要估计量、缺失处理、多重检验等。

A/B 与 A/A

A/B 是线上随机试验；A/A 给两组相同版本，主要检查分流、埋点与分析流程。一次 A/A 显著不必然说明系统坏了，也可能是假阳性；不能反复重抽直到“过关”，然后不交代过程。

> 群组随机化的信息量不能简单按个人总数判断。标准误应尊重随机化单位与组内相关结构。

批 注

我的理解 / 疑问 / 补充例子

NSW：约 1794 美元的实验差

数据里有什么?

445 人：185 处理、260 实验对照。实际 DTA 为 11 列，含 `data_id`；课件展示的核心分析变量为 10 列。

`re78` 是 1978 年收入；`re74`、`re75` 是此前收入；其他前定特征包括年龄、教育、族裔、婚姻与是否无高中文凭。

第一本账：效应有多大?

$$\bar{Y}_1 = 6349.14, \qquad \bar{Y}_0 = 4554.80.$$
$$\hat{\tau} = 6349.14 - 4554.80 = 1794.34 \quad \text{美元}.$$

两组方差构造的常用标准误：

$$SE(\hat{\tau}) = \sqrt{\frac{s_1^2}{185} + \frac{s_0^2}{260}} \approx 671.00.$$

正态近似 95% 区间：

$$1794.34 \pm 1.96 \times 671.00 \approx [479, 3109].$$

读法：这个实验样本中，收入平均增加的点估计约 1794 美元，但仍有较宽的不确定范围。

另外两本账

Fisher 检验问 sharp null 下观测差是否罕见。课件报告 10000 次重摇得到单侧 $p \approx 0.0027$，本笔记没有原随机种子及脚本来独立复现这一特定模拟值。

调整回归问加入前定协变量后，估计和精度怎样变化。点估计变化本身不证明随机化失败。

> 实验基准不是没有误差的真值；1794 美元不是人人受益额，也不是自动适用于其他人群的数。

批 注

我的理解 / 疑问 / 补充例子

Fisher：在零假设下重演抽签

sharp null 让反事实变成已知

$$H_0: Y_i(1) = Y_i(0), \qquad \forall i.$$

处理对每个人都无效，则一个人无论分到哪组，结果都相同。零假设下，只剩分配机制带来的随机性。

操作：保持结果不动 → 按原设计重摇标签 → 重算统计量 → 数至少同样极端的比例。

单侧、等概率枚举时：

$$p = \frac{\#\{T^{(b)} \geq T_{obs}\}}{\#\{\text{允许的分配}\}}.$$

如果分配不等概率，要按设计概率计算，不能一律数名单个数。

女士品茶：8 杯中选 4 杯

纯猜时共 $\binom{8}{4} = 70$ 种选择。设挑对的先奶杯数为 K：

$$P(K=k) = \frac{\binom{4}{k}\binom{4}{4-k}}{\binom{8}{4}}.$$

选对 k 杯先奶	0	1	2	3	4
组合数	1	16	36	16	1

“全对”单侧概率 $1/70 \approx 1.43\%$；“至少 3 杯”是 $17/70 \approx 24.29\%$。

与平均效应为零的区别

$ATE = 0$ 可以是正负效应抵消；sharp null 要求每个人都零效应。二者不是同一个零假设。

> 无需结果正态，不等于无需假设。检验依赖正确分配规则；只模拟部分分配时，还存在蒙特卡洛误差。Neyman 随机化推断也可针对有限总体。

批 注

我的理解 / 疑问 / 补充例子

两道手算：患者与豆腐脑

五患者：最极端，也可能不够显著

结果为 $1, 2, 3, 4, 10$；随机选 2 人治疗，实际抽到 $4, 10$。观测差：

$$T_{obs} = (4+10)/2 - (1+2+3)/3 = 5.$$

全部 $\binom{5}{2} = 10$ 个名单：

治疗名单	均值差	治疗名单	均值差
1，2	−4.17	2，4	−1.67
1，3	−3.33	2，10	3.33
1，4	−2.50	3，4	−0.83
1，10	2.50	3，10	4.17
2，3	−2.50	4，10	5.00

单侧 $p = 1/10 = 0.10$。小实验只有少量可能分配，p 值会离散，检验能力有限。

豆腐脑：检验关联，不直接识别因果

	甜	咸
男	2	6
女	7	4

固定边缘的 Fisher 精确检验：单侧约 0.1149；常用概率法双侧约 0.1698。证据不足以拒绝无关联，不等于证明口味完全相同。

区别：性别未真实随机分配，这里是条件关联检验，不因计算方式相似就变成性别因果效应。

批 注

枚举时，为什么必须包含实际那份名单？

不遵守、流失与外推：随机化的边界

不遵守：分到处理，不等于实际接受

用 Z 表示随机邀请或资格，D 表示实际处理。按原始 Z 比较：

$$ITT = E[Y|\,Z=1] - E[Y|\,Z=0].$$

它估计“提供资格或邀请”的效应。若直接按实际 D 分组，积极性等因素可能重新进入选择机制。

从 ITT 推到实际处理的因果效应，需要工具变量相关性、排除限制、单调性等相应条件；不是把未参加者删掉就行。

流失：只看留下者，可能破坏可比性

若副作用大或效果差的人更容易退出，最终完成者不再保证是两组可比样本。应报告两组流失与原因，使用有依据的处理和敏感性分析。

干扰与观察环境

组间传播、替代与污染会改变比较的含义。知道自己被研究可能改变行为；实验期间执行资源更充足，也会限制外推。

内部与外部效度

内部：在这批实验单位中，目标效应识别得对吗?
外部：换人群、时间、地区或规模，效应是否适用?

伦理同样属于设计：知情同意、对照待遇、风险和实验后的安排，应与实际研究相适应。一个实验内部识别好，不等于它应当实施。

> 非随机招募主要限制代表性；非随机失访则还可能损害内部可比性。两种“选择”不要混淆。

批 注

我的理解 / 疑问 / 补充例子

估计阶段与真实实验：设计之后仍要自律

RCT 为什么还加入协变量?

主要为了提高精度、处理预先规定的设计结构。随机化负责识别，但任意 OLS 调整在小样本、异质效应下可能有偏误和标准误问题。

Lin 式调整使用处理与去均值前定协变量的交互，配合适当稳健标准误；效率保证主要是渐近的。群组设计还须尊重群组相关。

实操纪律：预先规定协变量；不按结果挑规格；报告主要估计与合理敏感性；区分有限样本与渐近性质。

三个应用，要读懂随机化的对象

媒体访问实验：课件介绍访问权与鼓励的分层分配。开放入口不等于实际使用；资格效应、鼓励效应与实际使用效应需要区分。

eBay 广告实验：停止部分广告，观察本来不会发生的购买减少多少。已看广告者购买多，可能因为他们本来就有购买需求。

疫苗试验：课件以 8 对 162 个病例说明约 95% 的相对保护效力。在风险分母相近时，直觉近似为：

$$VE = 1 - \frac{\text{风险}_{\text{疫苗}}}{\text{风险}_{\text{对照}}} \approx 1 - \frac{8}{162}.$$

95% 是相对风险降低，不等于每个人有 95% 的绝对获益，也不等于绝对风险下降 95 个百分点。正式结果应使用论文规定的分析集和风险分母。

> 这些应用的具体外部数字来自课件介绍；本笔记重点核查设计逻辑，没有重新审计各篇原文的全部结果。

批 注

我的理解 / 疑问 / 补充例子

三个基本结构，三种控制后果

分叉：共同原因，该堵后门

处理 D ← 共同原因 X → 结果 Y

例：积极性同时影响培训报名与未来收入。合适地调整 X 可以阻断这条非因果路径；是否足够，仍取决于完整因果结构。

链：中介机制，可能挡住效应

处理 D → 中介 M → 结果 Y

例：培训 → 技能提高 → 收入。若研究总效应却控制培训后技能，就阻断了效应传递路径。直接效应需要另行定义和假设。

对撞：共同结果，控制反而打开路

变量 A → 共同结果 C ← 变量 B

例：颜值 → 走红 ← 演技。在总体中即使两者独立，只看走红者也可能产生关联。

控制对象	对相应路径的典型影响
非对撞点，例如链 / 分叉中间点	阻断路径
对撞点或其后代	可能打开原来阻断的路径

DAG 是假设清单：箭头有方向，无有向环；未画某条箭头也表达了结构假设。不能单凭相关大小决定箭头，更不能把“控制越多”当作识别策略。

> 局部片段帮助建立直觉，真正挑控制集合要检查整张图的路径，而不是见到一个分叉就机械操作。

批 注

各画一个专业相关的分叉、链与对撞。

从幸存者到三扇门：选择机制改变信息

为什么只分析留下的人会出问题?

假设处理与个人状况都会影响是否留在样本里，而个人状况也影响结果。只分析留下者，相当于条件化在共同结果上，可能打开非因果路径。

同样的思路可用于只看存活基金、只看成功企业、只看被录用者。是否产生具体偏差，要依据相应结构，不能只凭“筛过样本”四字下结论。

蒙提·霍尔：换门为什么是 2/3?

标准规则：三扇门一扇有奖；主持人知情，始终在未选门中打开空门，并提供换门机会。

最初选择	概率	换门结果
已选中奖品	1/3	输
没选中奖品	2/3	赢

所以换门胜率 2/3。主持人的行动规则决定信息如何被生成。若主持人不知情地随机开门，只是恰好开空，条件问题就不同。

自己画图的四步

按时间摆变量 → 补共同原因，包括测不到的 → 说明每条箭头及关键缺失箭头 → 检查拟控制变量在各条路径上的角色。

随机试验的图形直觉：随机分配阻断前定共同原因决定“分配”的通路。实际接受处理仍可能由个人因素决定，所以分配变量 Z 与实际处理 D 要分开画。

> 主持人如何选择门、谁进入样本、谁接受培训，都是“生成机制”问题。观察到相同表面现象，不代表背后机制相同。

批 注

我的理解 / 疑问 / 补充例子

两把钥匙：非混杂性与重叠

第一把：给定 X 后可比

$$(Y(1), Y(0)) \perp D \mid X.$$

在相同 X 下，处理选择不再携带潜在结果信息。直觉是：需要处理的混杂已被合适的 X 阻断。

若还有未测量的积极性、健康或资源，同时影响处理与结果，配得再漂亮也不能自动解决。非混杂性通常不能仅凭观测数据直接检验。

第二把：两种状态都要可能

$$e(X) = P(D = 1 \mid X), \qquad 0 < e(X) < 1.$$

假如年长者全接受培训，年轻者全未接受，那么年长人群缺少对应未处理比较对象。

正确边界：该群体效应通常仍可定义，但不能仅凭当前数据和这些条件非参数识别。模型若给出数值，是额外押注外推设定。

共同支撑怎样查?

离散特征可分层数人；连续和多维特征可看联合分布、得分分布及局部数据量。样本可以揭示明显问题，但有限数据不能证明总体正性在每处都成立。

“真实得分”上的重叠与“估计得分直方图”不是一回事。相近的估计得分也不替代协变量平衡检查。

> 两条件合称强可忽略性。先确定目标人群，再谈哪里有资格比较；删除支撑外处理者会改变目标范围。

批 注

我的理解 / 疑问 / 补充例子

回归调整：用结果模型借反事实

定义观测结果模型：

$$m_d(X) = E[Y \mid D = d, X].$$

在合适的因果条件下，$m_0(X)$ 可以提供处理组未处理潜在结果的条件均值。

ATT 的填补算法

1. 用对照组估计 $\widehat{m}_0(X)$；
2. 把每个处理者的 X_i 代入，预测其未处理结果；
3. 实际结果减预测结果，再对处理组平均。

$$\widehat{ATT} = \frac{1}{N_1} \sum_{i:\, D_i = 1} \{Y_i - \widehat{m}_0(X_i)\}.$$

若两支结果模型均估计，可标准化到全体：

$$\widehat{ATE} = \frac{1}{N} \sum_i \{\widehat{m}_1(X_i) - \widehat{m}_0(X_i)\}.$$

平均在哪些人的 X 上，决定目标人群。

三个风险

函数形式：真实关系弯曲，硬拟合直线可能填歪。
外推：处理者住在对照数据范围之外，预测靠模型。
局部样本稀少：虽有重叠，但信息太薄，预测不稳。

为什么控制回归系数不一定就是 ATE?

在特定充分控制设定下，OLS 可能给条件效应赋予与 $e(X)(1 - e(X))$ 成比例的权重。它强调不同目标权重的区别，不是任意线性回归都能直接套用的公式。

> 不能把课件的“随机化或同质性”简化成任意 OLS 因果解释的充分条件；还须交代控制方式、混杂和函数设定。

批 注

我的理解 / 疑问 / 补充例子

匹配：找谁、配几个、允许多远？

最近邻 ATT 的直觉是：对处理者 i，找对照 $j(i)$，再平均差：

$$\widehat{ATT} = \frac{1}{N_1} \sum_{i:\, D_i = 1} \left(Y_i - Y_{j(i)} \right).$$

尺或规则	含义
精确 / 粗化精确	逐项相同，或先分箱再精确匹配
欧氏距离	先处理量纲，否则大数值变量支配距离
马氏距离	利用协方差结构衡量接近程度
近邻 1:k	选 k 位最近对照；更多人可能更远
卡尺	最近邻也不能超过距离容忍线
半径 / 核	使用范围内多位对照，可按距离衰减
分层	在得分层内比较，再按目标权重汇合

可重复、顺序与样本范围

允许重复可以让多个处理者使用同一较好对照，但信息更集中。不可重复的贪婪匹配可能受顺序影响；最优匹配整体优化某个距离目标。

手算：处理得分 0.60、0.70；对照 0.62、0.56、0.30。 - 可重复 1:1：两人都配 0.62。 - 不可重复：先配者会影响后配者的选择。 - 卡尺 0.05：0.60 配 0.62，0.70 配不上。 - 半径 0.05：0.60 可使用 0.62 与 0.56。

> 卡尺删除处理者后，得到的是保留人群的效应。更多对照、放宽卡尺的偏差—方差方向是常用直觉，不是每个数据集的严格单调定律。

批 注

我的理解 / 疑问 / 补充例子

匹配的诊断：先看秤，再读效应

标准化均值差 SMD

$$SMD_k = 100\frac{\bar{X}_{1k} - \bar{X}_{0k,w}}{\sqrt{\left(s_{1k}^2 + s_{0k}^2\right)/2}}.$$

分子是处理与加权对照均值差；分母换成可比较尺度。常用 $|SMD| < 10\%$ 经验线，不是因果有效的证明。

还要看什么?

分布形状、方差、重要非线性和交互；匹配前后人数；删除的是谁；哪些对照被反复使用；结果对合理规格是否敏感。

不同软件对标准化分母有不同约定，必须说明并保持可比。均值差检验 p 值受样本量影响，不能只凭“不显著”宣布平衡。

匹配也可以看成加权

设对处理者 i 的对照权重为 w_{ij}，且每个 i 满足 $\sum_j w_{ij} = 1$：

$$\widehat{ATT} = \frac{1}{N_1}\sum_{i:\,D_i=1}\left(Y_i - \sum_{j:\,D_j=0} w_{ij}Y_j\right).$$

对照总体权重为 $W_j = N_1^{-1}\sum_i w_{ij}$。重复使用次数越多，影响力越大。

两条边界

平衡诊断检查设计表现，不证明无未观测混杂。

重复对照不等于新独立观测。 应用适合匹配估计量的标准误；最近邻匹配不能机械套所有普通自助法结论。

> 可以在不看结果的设计阶段根据平衡改进模型；仍应透明报告规则，避免只为单份样本打磨漂亮指标。

批 注

我的理解 / 疑问 / 补充例子

倾向得分定理：为什么一维有用？

定义与维数灾难

$$e(X) = P(D=1 \mid X).$$

多个连续变量同时接近的邻居很难找。倾向得分把处理概率相关的信息汇总为一个数，但不创造原本不存在的比较对象。

台阶一：真实得分是平衡分数

$$D \perp X \mid e(X).$$

因为 $e(X)$ 已是 X 的函数：

$$P(D=1 \mid X, e(X)) = e(X) = P(D=1 \mid e(X)).$$

对二元 D，该条件概率关系给出条件独立。

台阶二：非混杂性可以继承

若：

$$(Y(1), Y(0)) \perp D \mid X,$$

则：

$$(Y(1), Y(0)) \perp D \mid e(X).$$

直觉：在同一真实得分下，X 的分布在两组相同；既然给定 X 后已经可比，汇总后仍能形成相应可比性。

不要过度解读定理

它是关于真实概率和总体分布的结论，不是保证两个得分接近的人每项特征都相等。实际 $\hat{e}(X)$ 有估计误差，有限样本近似匹配还要诊断。

> 相同得分下的分布平衡，不等于个体“复制”。未观测混杂、支撑缺失和估计误差，都不会被定理自动抹去。

批 注

我的理解 / 疑问 / 补充例子

估得分：目标是可比性，不是分类冠军

常见的 Logit 估计

$$\hat{e}(X) = \frac{1}{1 + \exp\left[-(\hat{\alpha} + X'\hat{\gamma})\right]}.$$

以处理 D 为因变量，前定特征 X 为自变量。可以加入有依据的非线性或交互，也可采用合适机器学习方法。

变量选择靠因果结构：处理前测量是重要条件，但前定变量也可能是对撞点；处理后中介不能随意放入。仅预测处理、却非混杂的变量，也不能机械加入。

为什么 AUC 高不等于设计好?

几乎完美地区分两组，可能恰恰说明重叠差。目标是使相关协变量在设计后的两组可比，而不是分类正确率最高。

logit 尺度不是必需条件

$$\text{logit}(e) = \log\frac{e}{1-e}.$$

它常用于匹配距离与卡尺，不是所有场景必须采用。IPW 权重仍用概率 e，不能把 logit 值代入概率公式。

Embedding 能不能当特征?

可以考虑将处理前文本、图像转成表示，但应确认：保留了重要混杂信息；没有处理后泄漏；距离与目标可比性有关；高维不会让最近邻变远。可用于辅助得分或结果模型，仍需诊断。

Embedding 相对于原始信息可能降维，不能一律称为升维。其预测或语义相似能力，也不等于因果平衡能力。

> King–Nielsen 的批评提醒：某些贪婪 PSM 会增加失衡和模型依赖。它不等于倾向得分理论或所有加权方法无用。

批 注

我的理解 / 疑问 / 补充例子

IPW：用权重重建目标人群

ATE 的逆概率权重

$$\widehat{ATE}_{IPW} = \frac{1}{N}\sum_i \left[\frac{D_i Y_i}{\widehat{e}_i} - \frac{(1-D_i)\,Y_i}{1-\widehat{e}_i}\right].$$

处理组权重 $1/e$；对照组权重 $1/(1-e)$。某类人接受处理很罕见，一个实际接受者就需要代表更多同类的“处理世界”。

在因果识别条件下：

$$E[DY/e(X) \mid X] = E[Y(1) \mid X].$$

处理与对照两边分别还原，再求差。

ATT 只重新加权对照

$$w_i = \frac{\widehat{e}_i}{1-\widehat{e}_i}, \quad D_i = 0.$$

$$\widehat{ATT} = \bar{Y}_1 - \frac{\sum_{D_i=0} w_i Y_i}{\sum_{D_i=0} w_i}.$$

对照中越像处理者的人权重越大。$e = 0.1, 0.5, 0.9$ 时，该权重约为 $0.111, 1, 9$。

极端权重与有效样本量

ATE 中，一个 $e = 0.01$ 的处理者有权重 100。少数人可能主导结果。常用指标：

$$ESS = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}.$$

权重集中时，名义人数可能很大，ESS 却很小。

报告：重叠、权重分布、极值、ESS、平衡和修剪规则。修剪或限制权重可能改变目标或引入偏差，不是无代价修复。

> 上方 ATE 是 Horvitz–Thompson 写法；按各组权重和归一化的 Hájek 写法也常用。有限样本结果不必完全相同。

批 注

我的理解 / 疑问 / 补充例子

AIPW：预测打底，残差找补

设 $\widehat{m}_d(X)$ 为结果回归，$\widehat{e}(X)$ 为倾向得分。先把两支潜在均值分别写成：

$$\widehat{\mu}_1 = \frac{1}{N}\sum_i \left[\widehat{m}_1(X_i) + \frac{D_i\{Y_i - \widehat{m}_1(X_i)\}}{\widehat{e}_i}\right],$$

$$\widehat{\mu}_0 = \frac{1}{N}\sum_i \left[\widehat{m}_0(X_i) + \frac{(1-D_i)\{Y_i - \widehat{m}_0(X_i)\}}{1-\widehat{e}_i}\right].$$

于是：

$$\widehat{ATE}_{AIPW} = \widehat{\mu}_1 - \widehat{\mu}_0.$$

为什么说双重稳健？

若结果回归正确：相应组别中的残差条件均值为零；加权修正不会系统性改变正确预测。

若得分正确：加权残差能够修正错误结果预测带来的平均偏差。

在因果条件和适当正则条件下，两支结果模型正确，或者倾向得分模型正确，均可支持一致性。这里“结果模型正确”包括需要的两支模型，不是随便一支正确就行。

没有得到什么保证？

它不消除未观测混杂，不创造共同支撑，不保证小样本精确，也不保证两个模型都错时仍正确。

灵活机器学习还涉及过拟合、收敛速度与推断；交叉拟合用于减少同样本拟合带来的问题，但不替代识别假设。

> 双重稳健主要是估计性质。因果解释仍站在潜在结果定义、非混杂性和重叠的地基上。

批 注

我的理解 / 疑问 / 补充例子

NSW–CPS：对照一换，结论反号

保留 185 位 NSW 处理者，拿掉 260 位实验对照，改用 15992 位 CPS 普通劳动者作对照。

$$6349.14 - 14846.66 = -8497.52 \quad \text{美元}.$$

这混入就业困难培训对象与普通劳动者原本的巨大差异。

方法	美元	本笔记核对情况
实验基准	1794.34	已复核
NSW 减 CPS 朴素差	−8497.52	已复核
8 协变量线性回归	699.1	已复核
课件倾向得分匹配	1950.5	课件报告值
课件 ATT 加权	1241.2	课件报告值

为什么没有把后两行称为完整复现？

ZIP 未包含课件提到的 `figs_ch4.py`，无法核对全部得分、共同支撑、并列邻居处理等规则。

独立补充计算：8 协变量未惩罚 Logit、得分范围共同支撑、1:1 可重复最近邻，得到约 1729.75；但年龄 SMD 仍约 36.5%，不能宣布匹配合格。这是说明性规格，不是对课件算法的替代复现。

读懂课件的“130 位对照”

课件报告从支撑内 5817 位选到 130 位不同对照，为 185 位处理者服务。315 是不同个体总数，不等于权重意义的 ESS。

> 接近有误差的实验基准，不证明方法普遍最优。应先看重叠、平衡和样本范围，再看效应及不确定性。

批 注

我的理解 / 疑问 / 补充例子

PSM–DID：匹配之后，识别条件没有消失

课件介绍的金融应用

《股票市场财富效应与居民消费意愿——来自中国家庭微观调查数据的经验证据》，李家山、易行健、何启志、周利，《金融研究》2025 年第 4 期。

按课件：使用 CHFS 2013 / 2015 面板，区分股市参与与非参与家庭；先 Logit＋卡尺 1:2 匹配，再利用 2014 年末股市上涨作双重差分分析。

$$DID = \left(\bar{Y}_{1,\text{后}} - \bar{Y}_{1,\text{前}}\right) - \left(\bar{Y}_{0,\text{后}} - \bar{Y}_{0,\text{前}}\right).$$

两步分别做什么？

匹配改善处理前可观测特征的可比性；DID 比较变化，关键依赖未处理潜在结果的平行趋势，以及适当的无预期、样本构成和干扰条件。

做了 PSM，不代表平行趋势自动成立。 只有两个时期时，不能用它们直接检验冲击之前的趋势。

用检查单审读

- 匹配特征是否在处理前测量？是否含结果或处理中介？
- 共同支撑、保留人数、SMD 与分布诊断是否交代？
- 为什么未参与家庭能提供参与家庭的反事实趋势？
- 是否有其他同期冲击对两组产生不同影响？
- 改变卡尺、配比或合理对照设定，结果是否稳定？

课件转述 PSM–DID 系数 0.0813 等结果。由于未上传原文，本笔记不将这些转述当作对原文的独立审计；“标准化偏差”也不要误写成“标准误”。

批 注

我的理解 / 疑问 / 补充例子

两道核心题：药效与 ATT 的半个假设

轻燃：10 人服药，6 人减重

能说：这 10 位服药者中，观察到 6 人体重下降。

不能直接说：药使 60% 的人减重；因果效应 60%；所有人群都有相同疗效。缺的是这批人若未服药时的结果。

若历史未服药者有 10% 减重，$60\% - 10\% = 50$ 个百分点仍不是自动可信的药效；需论证人群、时间、观察窗口和其他行为可比。自愿者可能同时改变饮食，历史组也可能不同。

为什么 ATT 只需处理 $Y(0)$ 的混杂？

$$ATT = E[Y(1) \mid D=1] - E[Y(0) \mid D=1].$$

第一项已观察，缺的是第二项。若 $Y(0) \perp D \mid X$，处理者所在特征范围内有对照，且均值存在：

$$\begin{aligned} E[Y(0) \mid D=1] &= E_{X \mid D=1}\{E[Y(0) \mid X, D=1]\} \\ &= E_{X \mid D=1}\{E[Y(0) \mid X, D=0]\} \\ &= E_{X \mid D=1}\{E[Y \mid X, D=0]\}. \end{aligned}$$

因此：

$$ATT = E[Y \mid D=1] - E_{X \mid D=1}\{m_0(X)\}.$$

不需要再为处理者已观测的 $Y(1)$ 建立同样独立假设。若只识别平均效应，相应条件均值独立还可弱于完全独立。

> 这就是回归填补和 ATT 匹配背后的共同替换式。

批 注

我的理解 / 疑问 / 补充例子

辛普森悖论与必须补上的条件

合计有害、分层有益，为什么？

	服药康复率	未服药康复率
男	81/87，约 93%	234/270，约 87%
女	192/263，约 73%	55/80，约 69%
合计	273/350，78%	289/350，约 83%

服药组女性更多，而表中女性康复率整体更低。合计使用了不同性别权重，把构成差异混入药效比较。

因果解释还需条件：如果性别是混杂因素，且给定性别后没有其他混杂，则可分层比较，再按相同的目标性别分布标准化。层内差为正本身仍不证明药物有效。

阅读材料时的四条澄清

没有支撑：通常是现有数据下未识别，不是效应无法定义。

随机分配：不自动保证总体代表性和随机失访；Neyman 推断也不只适用于超总体。

第二讲第 19 页的六人表：效应依次为 1、2、0、1、1、1，平均为 1，并非每人都增加 1。观测差为零是 $ATT = 1$ 与 $B = -1$ 抵消；不能说项目没有把人抬高。

时间机器：普通“走第二遍”存在时间与残留效应；若假想完整复制世界、仅改处理且保留外部记录，则在该不可实现设定下确可比较。第二讲 P23 本身也区分了这两种情况。

> 澄清的目的，是避免把教学中的强调句背成无条件定理。优先记住定义、目标量和成立条件。

批 注

我的理解 / 疑问 / 补充例子

复习卡：六条式子与一周学习路线

六条式子：每条都要会解释条件

$$\tau_i = Y_i(1) - Y_i(0)$$
$$ATE = pATT + (1-p)\,ATU$$
$$SDO = ATT + B$$
$$SDO = ATE + B + (1-p)\,(ATT - ATU)$$
$$D \perp (Y(1), Y(0))$$
$$(Y(1), Y(0)) \perp D \mid X, \quad 0 < e(X) < 1$$

建议分七次完成

次序	学什么	必须留下的成果
1	问题与回归	把一个相关问题改写为干预问题
2	ESG 案例	解释符号翻转、显著与真值的区别
3	潜在结果	重算六县表和两种分解
4	随机试验	手枚举五患者名单并计算 p 值
5	DAG	画自己的图并解释控制集合
6	匹配与加权	交重叠、平衡、样本流转说明
7	论文与选题	写一页研究设计，不先堆模型

自测标准：能清楚说明“谁、什么干预、何时测什么结果、目标效应、比较对象、关键假设、最大威胁”，才算把公式接到研究上。

批 注

我的理解 / 疑问 / 补充例子

课程大作业：已经确认的要求

项目	课件要求
考核占比	期末大作业 100%；课后思考题不计分
形式范围	与因果推断相关；实证、项目、综述、讲解、读后感等均可
展示	现场演示，预计 15 组、名额有限
替补形式	不现场展示：报告＋讲解视频
报告字数	1000—10000 字
展示时长	5—15 分钟
分组	自由组队，每组不超过 6 人，可跨班
署名	学号、姓名、分工，防止搭便车
评价	100 分制；深度、广度、学术性、趣味性
可复制性	附数据与程序，使别人能够跑通
学术诚信	引用诚实，数据真实，清楚注明来源
截止	考试周结束当天；尚无可确认的公历日期
提交渠道	待课程群通知

已记录的后续协作约定

后续帮助完成大作业时，将以本表核对形式、字数、分工、展示时间和可复现性；若课程群更新，以用户提供的最终通知覆盖旧要求。没有写明的日期、格式和额外限制，不自行编造。

建议，不是老师额外要求：先选范围可控、数据可获得的问题；比起堆方法，更应把目标量、识别逻辑和证据边界说清楚。模拟数据可用于教学说明，但必须明确标注，不能冒充真实调查或实证证据。

批 注

课程群后续更新：日期 / 渠道 / 形式 / 其他。

一页研究设计模板：以后从这里开始

选题先填九个格子

1．问题：什么具体动作，对谁的什么结果产生影响?

2．单位与时间：人、企业、地区？何时处理、何时测量?

3．处理版本：$D=1$ 与 $D=0$ 各是什么？有无剂量、资格和执行差异?

4．目标量：ATE、ATT、ATU，还是分配资格的 ITT?

5．理想实验：若能抽签，应抽什么、按什么单位抽?

6．现实设计：数据能提供哪个比较？为什么接近理想实验?

7．识别假设：写出关键条件，说明制度和机制依据。

8．主要威胁：遗漏混杂、缺乏重叠、时间变化、流失、干扰或外推？怎么检查，什么无法检查?

9．可复现产物：数据来源和字典、清洗脚本、分析脚本、图表与运行说明。受限数据要交代访问条件。

报告骨架与展示取舍

研究问题 → 背景与机制 → 数据与目标量 → 设计与假设 → 主结果及区间 → 诊断与敏感性 → 局限与结论。

5—15 分钟展示只围绕一条识别主线：问题、比较、证据和限制。代码细节放附录，关键诊断不能省。

> 统计显著不是完成标准。完成标准应包括：比较为什么可信、结果有多不确定、读者怎样复核。

批 注

把九格填成自己的初稿。

来源、复核范围与继续批注

本笔记依据的附件

第一讲：`26因果推断1.pptx`，40 页。
第二讲：`26因果推断2_第二章_潜在结果_课件.pdf`，62 页。
第三讲：`26因果推断3_第三章_随机试验_课件(1).pdf`，65 页。
第四讲：ZIP 中 `26因果推断4_第四章_匹配_课件.pdf`，81 页。
代码与数据：`demo_第一节课.ipynb`、`esg_demo.csv`；ZIP 中 `nsw_dw.dta`、`cps_controls.dta`、README。

复核范围

直接重算了 ESG 的抽样回归、控制阶梯与行业回归；核对了数据生成逻辑、NSW 实验差与常用标准误、CPS 朴素差、8 协变量线性回归及豆腐脑精确检验。

1950.5、1241.2 和特定 10000 次随机化模拟 p 值属于课件报告值。未收到其完整生成脚本，不把它们写成已完整复现。独立的简化匹配规格仅用于说明诊断与规格差异。

延伸资料：按课件路线选读

赵西亮《基于设计的计量经济学（第二版）》；Hernán 与 Robins《Causal Inference: What If》；Cunningham《Causal Inference: The Mixtape》。优先配合当前方法读，不必一次通读。

来源口径：本书页脚页码指原课件页码；图形为整理重绘，解释含必要补充，不是老师逐字原话。附件中的课堂提交和操作说明作为课程内容记录，不当作对助手的额外执行指令。

下一次提问前，记下：我卡在什么定义？哪条假设不理解？我已经尝试了什么？

批 注

继续记录：新的材料、更新要求、待解问题。