一条合格回复值多少 Token？

生成式 AI 辅助上市公司投资者问答的成本、质量与边界

A＋B 工作稿 v0.6｜2026 年 10 月 22 日更新；原件核查 10 月 22 日｜模型：DeepSeek＋千问

本文件包含两页问题说明、可继续写入报告的前三章草稿，以及三人团队执行安排。文献和监管案例已有来源；实验设计尚待预实验冻结。当前没有模型实验结果、人工耗时结果或因果结论，不能作为比赛最终稿提交。

两页问题说明（第 1 页）：研究什么，为什么值得做

核心问题是：文本生成价格降低后，为什么交付一条可信的投资者回复仍需要投入？我们的研究对象是一条真实问题及其提问前可获得的公开证据，观察从证据整理、草稿生成到人工核验修改的完整过程。

现实起点来自思美传媒事件。证监会浙江监管局〔2024〕4 号处罚决定认定，公司在互动易的有关回复与实际情况不符，构成误导性陈述，对公司罚款 150 万元、对相关责任人罚款 100 万元。[R1] 该案例说明回复内容可能产生经济与法律后果；监管决定没有将其认定为 AI 事故，本文也不这样描述。罚款不能直接转化为实验里每次错误的预期损失。

研究同时关注“有信息”和“有依据”。一条回复即使措辞流畅，若事实、期间或来源错了，也未必能使用；反过来，证据已经足够却只写“请关注公告”，也没有完成解释任务。因此，我们采用“合格”而非“法律合规”：合格只表示通过预先制定的事实、证据、覆盖及回答边界标准。

三个待回答的问题：第一，按单次生成费用排序的模型，按合格草稿成本排序后是否仍有优势？第二，先明确可回答部分和证据缺口的流程，是否降低无依据回答，同时增加过度拒答？第三，AI 减少的撰写时间，有多少被核验和修改重新消耗，Token 降价又能使最终交付成本下降多少？

社会意义从上述生产过程展开。公开互动可能降低中小投资者理解公告的门槛，但本研究只直接测量回复质量、时间和成本。信息公平、市场效率和投资者保护是机制讨论及后续验证方向；我们不以学生实验宣称已经改善了市场收益或市场公平。

本文预期贡献是把模型价格、回复可用性和人工工作连接起来，而不是宣称首次在互动平台研究中使用大语言模型。研究结果也可能显示：边界判断无明显收益、人工辅助没有节省总时间，或不同模型没有稳定差异。这些结果均应保留。

两页问题说明（第 2 页）：怎样得到可信答案

原计划为 20 题预实验、80 题正式实验，两者不重合；公司目标为同一交易所的 8 家非金融公司，按统一行业分类标准选两个行业。两种模型各执行直接生成与边界判断后生成，正式阶段共 320 份草稿。当前建立了 4 家公司 20 题候选，已归档 7 份上传 PDF；智动力年报仍缺，独立人工复核与模型调用尚未完成。9 题能定位实际提问时间；11 题只有说明会日期，需要补证或替换。

四类问题暂定为直接事实、综合解释、部分可答、资料不足或存在回答限制。最后一类进一步区分“当前证据不够”和“价格预测等回答边界”，不能把资料没找到视为依法禁止披露。来源包括互动易云访谈，以及公司披露的网上说明会记录，必须分别报告，不能统称为日常互动易原帖。

两种流程的输入问题、证据和基本约束一致。直接生成要求依据材料撰写回复并列出处；边界流程增加可答事实、证据缺口与回答限制的结构化清单，再给出最终回复。评分时只显示最终回复，完整输出仍用于 Token 和费用核算。我们不要求或评价模型的内部思维过程。

A 现在兼任 B，已接触样本答案，因此退出人工计时作答。C、D 已确认各承担 24 次任务，各 12 次纯人工、12 次 AI 辅助；同一道题由不同人完成两个条件，每人只做一次。A 统一主评 48 个人工最终稿，C/D 交叉次评且不自评；次评者已经处理同题另一条件，须如实披露这一限制。AI 草稿拟由 A 和 D 独立评分。

主要输出是合格率、无依据回答率、过度拒答率、人工总用时和每条合格产出成本。API 费用、可共享的证据准备、人工阅读核验修改、部署维护摊销分别记账，研究专用评分工作另列。工资取 60/120/240 元每小时等情景值，不能称为企业实测工资。若合格数量为 0，单位成本记为未定义，不写成 0 元。

下一步按依赖推进：先核已有原时间题并归档，完成连通与试评；再补 20 题、修订手册；在正式输出产生前冻结样本、输入、配置、指标和人员分配。正式规模仍以 80 题为目标。若时间迫使缩减，应提前记录原因和新规模，不能看完结果再删题。

第一章 引言：一条回复的价格与代价

一条投资者提问往往很短，却可能需要多份公告才能回答。投资者询问研发费用为何增长，回答者既要核对年度和季度口径，也要判断公开资料是否支持某个项目的投入归因；询问海外业务时，回答者要区分境外收入、海外子公司的收入，以及尚未落实的扩张计划。文本生成只是这一过程中的一环。

大语言模型能够帮助组织表达、归纳材料和起草回复。与此同时，语言上的确定性并不自动意味着事实上的确定性。模型可能把提问中的假设当作事实，把产品应用方向写成已经实现的订单，把某期数据移用到另一期间，也可能为了避免错误而拒绝解释材料中已有的信息。采用 AI 的收益取决于它在整条工作链中减少了哪些劳动，又增加了哪些核验任务。

思美传媒案例给这一问题提供了现实背景。监管决定认定，2023 年 11 月 27 日的相关互动易回复与实际情况不符并构成误导性陈述。[R1] 这一案例能够说明公开回复的责任要求，但既不能证明 AI 造成该事件，也不能据此估计模型答错一次的损失概率。本文从这一案例提出研究问题，随后以公开资料上的受控任务测量回复生产成本。

制度要求同时强调及时回应与信息质量。《上市公司投资者关系管理工作指引》要求主动回应投资者诉求、平等对待投资者；其第十三条规定披露应真实、准确、完整，第二十五条列出证券价格预测或承诺等禁止情形。[R2：PDF 第 2、5、8 页] 因而，评价不能只计算回复是否出现错误，还应考察它是否完成可以完成的任务。空泛的安全措辞与没有依据的具体承诺，可能以不同方式降低回复的使用价值。

本文以“质量调整后的单位产出成本”连接技术与经济问题。生成费用是投入，合格回复才是产出；人工核验则是让草稿达到可交付标准的工作。我们分别考察草稿环节与人工完成后的交付环节，避免拿 320 份未经人工处理的模型输出，直接计算仿佛已完成企业审校的交付成本。

核心研究问题不预设价格较低的模型一定更差，或边界流程一定更优。两个模型的精确版本及实际计价需由 C 在调用时记录，若名义单价相同，则比较实际 Token 消耗、合格率和人工处理时间。本文也不预设近期 Token 价格已经下降某个幅度；“下降 50%”是明确固定其他条件的反事实情景。

报告将依次介绍制度与文献、样本与实验设计、质量和时间结果、成本敏感性，再讨论人机分工与信息服务的可能影响。当前工作稿完成的是研究框架及方法准备，结果、摘要中的实证结论和政策建议须待数据产生后撰写。

第二章 文献与分析框架

2.1 平台互动的价值取决于内容与使用场景

Chen、Mayew、Ren 和 Zhu 的 2025 年 8 月 5 日工作稿讨论投资者平台活动与信息不对称。样本覆盖 2010 年至 2022 年 6 月，回归数据包括 4,680 家公司、7,818,963 个公司—交易日观测。[L11b：正文第 9—10 页，PDF 第 10—11 页] 论文区分提问与评论，并对回复质量进行文本分类，提示回复数量不能替代内容质量的测量。

该研究为本文提供的是指标选择与机制背景。其文本分类准确率是分类器在特定标注任务中的表现，并不是生成式 AI 回复的事实正确率；论文也未测量生成和核验一条回复的成本。关于及时性与质量的分组差异，应按对应表格报告，不得把所有比较都写成显著。2025 版本与早期 2022 工作稿属于同一研究的不同版本，不能重复算作两篇独立证据。

徐寿福、郑迎飞和罗雨杰研究网络平台互动与股票异质性风险，使用 92,155 个公司—季度观测，构建问答活动、文本长度与基于市场模型残差的风险指标。[L14：第 156—159 页；机制讨论第 162 页] 研究揭示互动活动也可能伴随分歧和风险变化。这提醒我们，增加回复供给本身并不是社会收益的充分条件；关联性结果更不能直接当作 AI 回复影响资本市场的因果证据。

2.2 大语言模型测量与大语言模型生产是不同问题

樊犇、吴燕博和刘恒源利用大语言模型识别投资者互动监督，并研究其与企业真实盈余管理的关系。论文样本为 2011—2023 年沪深 A 股的 25,996 个公司—年度观测，文本处理中使用 Qwen2.5-72B。[L13：第 98—99 页] 该研究说明 LLM 已经进入互动文本研究，本文不能再使用“首次将大模型应用于投资者互动”这样的创新表述。

两者的任务不同：上述研究使用 LLM 构造经济变量，本文让 LLM 生产有待核验的回复，再观察质量与成本。论文中的监督效应或文本处理能力，不能替代对生成回复的独立评分。其真实盈余管理指标在基准与稳健性部分的组合符号也应按原文分别记录，避免在综述中悄悄统一。[L13：第 97、99 页]

综合三篇文献，本文将贡献限定为一个可操作的组合：真实问题、历史时点证据、回答范围识别、人工加工时间和合格产出成本。现有阅读支持这一研究定位，但还不足以声称在所有数据库中不存在相同研究；正式定稿前应保存补充检索的关键词、日期和排除记录。

2.3 从生成成本到可信交付成本

回复生产可以分为资料准备、草稿生成、核验修改和交付管理。资料准备具有可复用性：同一份年报可能支持多条问题；但新公告、时点限制和口径差异会持续产生维护工作。生成费用通常按输入、输出和缓存等用量计费，人工核验则依赖材料难度与模型错误形式。

据此提出三个可检验预期。其一，单次生成费用的排序未必等于合格草稿成本的排序。其二，边界清单可能降低无依据陈述，但也可能增加输出长度和过度拒答，净收益方向交由实验判断。其三，人工辅助的时间优势取决于阅读核验与修改的增加是否小于撰写时间的减少。三个预期均允许零效应或相反结果。

“Token 价格下降 50%”用于识别费用结构的作用。若质量、用量、人工时间和其他投入保持不变，最终总成本的下降比例等于原 API 费用占总成本的比例乘以 50%。例如 API 占比 10%时，总成本只下降 5%；这是算术情景，不是本研究已经观察到的占比，更没有计入需求增加、模型质量变化等动态反应。

第三章 数据、实验与评价方法（待预实验冻结）

3.1 样本与提问时点

正式目标为同一交易所 8 家非金融公司、80 道问题；行业归属将采用同一分类标准并核对代码。现有候选公司池分为电子制造与家电制造两个业务组，业务分组尚不能替代已核实的法定行业分类。正式问题拟取 2026 年 5 月至 9 月，预实验可使用较早问题；苏泊尔 2026 年 4 月问题属于预实验，不计入正式窗口。

采集单位是具有独立来源与时间的真实提问。问题主表保留原文、规范化文本、修改说明、公司、平台、活动类型及可核对的定位信息。页面中同一问题在提问区和回复区重复出现，只算一次。PDF 断行可合并；明显错字不得无痕改写。机构提问和个人提问分别记录，不根据匿名网名推定投资者身份。

正式输入只允许使用实际提问时点之前公开的证据。若已知提问日但披露分钟不清，采用前一日末作为保守截点；若只知道说明会活动日，无法排除提前征集，就不能声称该截点必然早于提问。此类题标 U，补原始时间或替换；若用于活动日前信息集的探索任务，应单独定义并报告，不能混入严格时点主样本。

每份证据记录标题、披露日期、印刷页码、PDF 物理页序、出处 URL、原件哈希、摘录及适用题目。不能把报告期末当作披露日期，也不能用事后公司回复证明提问前资料充分。原回复只放在隔离表中供事后讨论，答案标准由公告与规则独立建立。

目前 20 题候选来自 4 家公司：智动力 5 题、苏泊尔 4 题、老板电器 5 题、立讯精密 6 题。其中 9 题有原平台精确时间，11 题来自网上说明会记录且缺原始提交时间；暂定 A/B/C/D 类数量为 2/5/8/5。D 类集中于立讯，不能用这一便利样本推断类型差异。正式样本需在各类型中覆盖多家公司，完整列出采集、排除、补证与最终冻结数量。

3.2 可答范围与答案标准

每题先划分事实要求、解释要求和未来或边界要求，再对应证据。A 类以直接事实提取为主；B 类需要计算或综合；C 类包含可答与不可确认部分；D 类再区分资料不足和明确回答限制。U 表示标准未决，不是第五种用来评分模型的难题类型。

“缺乏证据”始终限定在已记录的检索范围及冻结证据包内。对于客户合作、股东户数或经营规划，未在一份年报中找到并不意味着公司从未披露。若补检索发现提问前已有材料，应补入证据并修改分类。不得为制造模型错误而故意漏掉已发现的重要材料。

苏泊尔候选题展示了标准构建本身的工作量。年报第 12 页的收入构成表与第 13 页另一产品表，对食物料理电器列示不同金额和同比变化。上传原 PDF 及视觉核查确认差异存在：两产品在第 13 页相对第 12 页分别相差正负 17,294,550 元；相互抵消不解释差异原因，仍需查更正或口径说明。该题暂记 U，不能把其中一个数字设为唯一正确答案。老板电器另一候选题则需区分工程销售渠道与投资者口中的 B/C 端；工程占比下降不能直接证明 C 端复苏。[公司来源详见工作簿 E09、E17]

3.3 模型与流程对照

模型家族为 DeepSeek 与千问，API 总预算上限 100 元。精确模型 ID、地域、服务日期、参数、推理开关、缓存与计价方式由 C 连通测试后冻结；使用可变别名时同时保存服务返回的版本信息。两种流程禁用在线搜索，输入同一问题和同一证据，以免把资料差异误记为生成流程差异。

直接流程给出最终回复与证据引用；边界流程先输出简短的可答项目、缺口和限制清单，再给出最终回复。清单属于可审计的任务输出，不索取内部思维链。最终回复使用相同篇幅约束，边界清单允许额外输出，其 Token 和费用全部计入该流程；是否达到上限、截断或失败均记日志。

正式 80 题在四个模型—流程组合各运行一次，形成 320 份草稿；问题是配对比较单位。错误调用与重试保留，不挑选最满意的一次作为默认结果。重试规则、温度等参数以及主运行与可选重复的区分在预实验后确定。单次输出不能完整描述模型的随机性，应作为局限而非伪装成稳定能力。

历史问答可能已经进入模型训练数据。禁联网和隔离事后回复能够控制本次输入，却不能证明模型没有见过答案。评分只接受冻结证据支持的陈述；回答即使碰巧与事后回复一致，没有提问前证据支持仍不合格。该办法降低后见信息的影响，但不能完全消除预训练记忆污染。

3.4 三人团队的人工任务与盲评

A 负责样本、证据与答案，不参加计时写作。正式人工子样本目标为 24 题，每类 6 题，C、D 各处理每题一次；对每一道题，一人纯人工 H，另一人 AI 辅助 HA。每类内部随机分配 3 题 C 为 H、3 题 C 为 HA，D 取相反条件，从而每人 12 次 H、12 次 HA。CSV 中的 SLOT 编号仅是分配槽位，实际题号及顺序仍须随机化并冻结，不能照收集顺序机械分组。

H、HA 获得同样的证据与工具使用约束；HA 额外获得预先冻结配置生成的一份草稿，不自行挑选更好的模型结果。AI 辅助配置可依据预实验中明确标准选择，不能利用正式结果选择。纯人工不得调用其他生成式 AI。计时拆成阅读查找、核验、撰写修改和等待，暂停、超时及失败保留；同一人的两种条件交错安排，避免条件与疲劳顺序完全重合。

在人工任务结束前，C/D 都不能看正式 24 题答案或未分配草稿。C 可以维护 API 与日志，但不人工阅读这些题的其他输出；D 用预实验制定手册，不参与正式 24 题答案核对。正式 24 题的答案在人工任务前由 A 维护，具有缺乏第二位未接触任务者事前复核的限制；可在事后统一核查并报告敏感性，不能声称这一限制不存在。

AI 草稿由 A 与 D 独立评分，隐藏模型、流程标签及边界清单，保留真实引用以便核验。对人工 48 份最终稿，A 为统一主评，C/D 只交叉次评对方作品、不自评。由于次评者已完成同题另一条件，其判断并非完全未接触任务的盲评；报告主评结果并列次评敏感性，不使用“四名受试者、两名完全独立盲评者”的旧描述。

3.5 指标与评分

主指标为按事前规则判定的合格与否。事实和数值需正确，引用需实际支持对应陈述，可答核心要点需覆盖，不得出现无依据的关键断言，资料缺口与价格承诺等边界应处理恰当。重要事实错误或越界不能靠文风分数抵消。部分可答题必须回答可答部分；资料不足题则允许有依据地解释缺口。

同时报告事实错误、引用不支持、无依据回答、过度拒答和核心要点覆盖。过度拒答的分母限定为存在可答核心的题目或要点，不把正确拒绝目标股价的 D 类题计作过度拒答。指标分母、容许四舍五入范围、关键错误定义及歧义处理由 D 在预实验手册中给出例子，再冻结版本。

保留两位评分者讨论前的原始评分，报告一致率与适用的 Cohen's kappa，并提示类别不均衡时的解释限制。分歧先回到证据和规则，记录修改人及理由，不以 A 身份直接覆盖另一个评分。如果运行后发现答案标准存在未决缺陷，保留原样本与费用，报告未决数量，并给出未决全部通过/全部不通过的范围，不能静默删除难题改善结果。

3.6 成本和统计分析

对某一模型—流程组合，合格草稿 API 成本＝该组合全部调用费用÷合格草稿数量。计入按预定规则发生的失败与重试费用；免费额度下实付为零时，另列按同期参考价重算的费用，避免把赠送额度当长期成本。输入、输出、缓存及额外推理计费字段分别保存。

对人工子样本，合格交付成本＝（对应 API 费用＋人工任务时间×情景时薪＋资料准备分摊＋部署维护分摊）÷最终合格回复数量。H 的 API 项为零；资料准备如两条件共用，要分别报告共同底座与条件新增成本。一次准备费用不能在同一汇总账中重复相加；比较两种独立部署方案时，则要明确每个方案各自承担哪部分底座。部署摊销按明确业务量情景计算，不默认以实验调用数代表企业业务量。

主时间比较包括所有按分配开始的任务，同时报告最终质量；只分析合格任务可能造成选择偏差，可作为补充而非唯一结果。24 道题构成配对，需同时展示 C/D 个人差异。模型结果按题配对比较四条件；80 题不能被当作 320 个独立样本。报告差值和区间，问题层面重抽样时保持同题四输出成组，并讨论同公司题目相关性和仅 8 家公司带来的推断限制。

由于四类正式题计划近似均衡，这一总体均值对应研究设计的任务组合，不等于上市公司日常真实问题频率。应同时呈现各类结果；只有取得可信的业务频率权重后，才可另算情景加权成本。避免将便利选样和两名学生的速度直接外推为企业员工效率。

第四至第六章的待填结果与写作接口

第四章由 C 提供逐题配对输出和 Token 账，D 提供独立评分与错误类型。先给样本流转图，再给四条件合格率、无依据回答与过度拒答的并列表。第五章同时展示 48 次人工任务质量与总用时、费用构成、Token 降价 50%及人工时薪敏感性。第六章仅根据结果讨论采用条件、责任分工与中小投资者的信息获得；明确公开证据、模拟角色、便利样本、记忆污染和人员不足的局限。

推荐图表依次为：样本采集与排除流程；四条件质量与成本散点；无依据回答—过度拒答权衡；H/HA 逐题时间差与质量；交付成本构成；Token 价格折扣敏感性。图中不得预填演示数据冒充实测值。每幅图旁保留数据文件、计算脚本和所支持的一句结论，待结果产生再写摘要。

A＋B 执行安排与交接

你现在负责研究逻辑、原问采集、时点证据、参考答案、文献与统稿。我已提供 20 题候选、21 张事实卡、答案草稿、文献页码、数值复算和本稿，并归档 7 份 PDF、制作 2 题连通包。你优先补智动力 2025 年报并作人工核对；我继续核证、补正式样本和修订文稿。已收到的 7 份文件无需重复上传。助手完成摘记不能登记成已经有两名人类评分者复核。

C 先交模型连通及计费日志，D 先交试评手册和争议。2026 年 10 月 22 日，你已确认 C、D 各承担 24 次人工任务；具体启动时间和正式题目分配仍待落实。如执行中工作量无法完成，应在正式数据产生前调整设计。任务通知已经写成可转发文本，但尚未替你向任何成员发送消息。

以当前实际进度安排：下一工作段先以 P-A07 和 P-A08 完成接口连通、费用记录与试评；P-A06 保持 U，智动力 5 题等待年度报告原件；并行补 11 题原始时间及 D 类证据。接下来补齐 20 题、调整类型与公司覆盖，再冻结正式样本。原计划 10 月 20 日已完成冻结的节点已经落后，不能继续写作“已完成”。10 月 25 日完整初稿和 10 月 28 日定稿仍可作为内部目标，但应按数据进度检查可行性。

最终提交要求仍须对照比赛原始通知核实：既有方案记载 10 月 29 日 22:00 前、天津大学分赛场、Word 和 PDF 及指定邮箱。尚未核对官方通知与 AI 使用要求，也没有代发提交。若比赛要求披露 AI 辅助，应如实记录本轮在检索、整理、起草和校核中的使用。

参考来源与页码说明

[R1] 中国证监会浙江监管局：《行政处罚决定书〔2024〕4 号（思美传媒、李子木）》。网页无 PDF 页码，定位“违法事实”与“处罚决定”段。https://www.csrc.gov.cn/zhejiang/c103950/c7459526/content.shtml

[R2] 中国证监会：《上市公司投资者关系管理工作指引》，证监会公告〔2022〕29 号，落款 2022 年 4 月 11 日，2022 年 5 月 15 日起施行。正文与 PDF 页序一致；第 4 条见第 2 页，第 13 条见第 5 页，第 25 条见第 8 页。https://www.csrc.gov.cn/csrc/c101954/c2334702/content.shtml

[L11b] Chen, Zhenhua; Mayew, William J.; Ren, Wentao; Zhu, Pengcheng. Retail Investor Interactive Platform Activity and Information Asymmetry Among Investors: Should Regulators be Concerned? 工作稿，2025-08-05，SSRN 4281898。PDF46 页，正文页码＋1＝PDF 页序。样本正文 9—10 页；分类 15—16 页；回复质量 18—19 页；时效 21 页；附录 C33—34 页；表 6B 正文 45 页。https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4281898

[L13] 樊犇、吴燕博、刘恒源：《投资者互动监督与企业真实盈余管理——基于大语言模型的证据》，《审计与经济研究》2026，41(4)：94—104。PDF11 页，印刷页码－93＝PDF 页序。指标 97—98 页，样本及基准表 99 页。https://xbbjb.nau.edu.cn/sjyjjyj/article/abstract/20260204010

[L14] 徐寿福、郑迎飞、罗雨杰：《网络平台互动与股票异质性风险》，《财经研究》2022，48(10)：153—168，DOI：10.16538/j.cnki.jfe.20220614.102。PDF16 页，印刷页码－152＝PDF 页序；样本 156 页、变量 157 页、结果 159 页、机制 162 页。https://qks.shufe.edu.cn/j/PDFFull/17794c14-b22d-4e71-b91b-053fc480a45a.pdf

公司证据[E01—E21]：详见配套工作簿“02_证据与页码”及下载清单。事实卡为研究者转述，最终逐字引用应回到原 PDF；已归档 7 份原件的哈希见 15 号清单；未归档文件仍不填写原件哈希。参考答案与实验结果属于不同材料，前者不能写成后者。