D：评分规则草案与待确认口径

v0.9 校准建议｜尚未冻结，也没有已评分输出。请先基于原页独立拆解问题，再给出修改意见；A/D 在正式输出生成前冻结版本。

评分单位与材料

单位为一条最终回复及其引用。只看匿名编号、题号、最终回复、真实引用和统一证据，评分时不看模型、流程或边界清单。两题 8 个槽位现在只是计划编号；收到 C 真实输出后才填评分。智动力 5 题现在只做证据核对，不增加模型调用。

先完成 7 题独立事实提取：可答核心要点、资料缺口、关键错误例子和页码。不要先读 A 参考答案或公司事后回复；若已看过，在确认表写明范围，保留复核价值但不登记为未暴露的独立提取。公开仓库可访问答案，分包无法技术上保证盲法。

四项 0—2 分与合格判定（待 D 确认）

F 事实数值：2＝重要事实、单位、期间、计算均有依据且正确；1＝存在不改变核心含义的轻微错误；0＝存在影响结论的重要事实错误。

E 证据引用：2＝核心事实引用可定位且确实支持；1＝可支持但标注不完整或定位不清；0＝伪造、错引或核心陈述无证据支持。

C 核心覆盖：2＝完成该题全部已冻结的可答核心；1＝只完成部分，或用笼统措辞替代关键解释；0＝没有完成任何可答核心。全题无可答事实时，按该题已冻结的缺口说明/边界回应要点评分，不能因为无事实可答就自动判低分。

B 边界处理：2＝明确区分事实、推断和未知，未添加关键无依据断言；1＝缺口表达含糊但无关键越界；0＝将计划说成实绩、采信提问前提、无依据承诺/预测，或其他事前定义的关键越界。

暂建议合格＝四项均为 2，关键错误=否，标准未决=否。任何关键事实错误、伪造引用或关键越界不能用文风补分。这个阈值由 D 试评后提出修订、A/D 讨论冻结；不能先看正式模型结果再改阈值。轻微错别字且不影响意思不直接扣事实分。字数/JSON 格式问题单列，不自动等同事实失败。

同时记录的错误和分母

无依据回答：出现会影响投资者理解的、冻结材料无法支持的事实或因果断言。过度拒答：题目存在可答核心，但用拒绝或“请关注公告”等方式实质回避；必须标出被回避的核心和依据页码，不能把恰当拒绝预测股价算错。

另记事实错误、引用不支持、核心覆盖数/应覆盖数。分母事先写明：合格率按预定生成槽位统计，并并列成功生成子集；失败/空输出在生产流程口径为不合格，事实错误率不把无输出说成“无错误”。过度拒答率仅用存在可答核心的有效回复；全不可答题不进入该分母。两题只覆盖两类任务，不能据此代表全部题型。

纯数值优先按原金额计算后四舍五入到显示精度；可接受范围应等于该显示精度的舍入区间，单位和分母不能换。复杂计算或歧义必须写进题目标准，不临场放宽。先判断语义上的等价答案，不要求逐字复述 A 草稿。

标准 U＝证据冲突、时点不清或答案标准无法确定。U 不等于模型答错，也不等于全不合格；保留样本、费用、原评分，另报未决及敏感性范围，不能静默删除。技术失败与标准 U 分开标记。

分歧与计时

A/D 各自先保存原评分，再讨论；记录分歧维度、各自理由、原页、协商结论和规则版本变化。不得覆盖讨论前原表。后续报告一致率和适用的 kappa 并说明小样本/类别不均衡限制。

正式人工计时分阅读、撰写、核验、修改四类互斥活动；工作中切换类别时停前一项再开后一项，暂停不计活跃时间但另列原因。活跃总时间应等于四项之和，不把 API 等待重复计入；无法拆分的实际记录如实标注。正式任务 ID 尚为空，不现在填实测数据。

你先完成正式 24 次作答，再接触对应正式题参考答案和 AI 草稿评分。A 已接触答案，不做计时作答。人工最终稿 A 主评、C/D 交叉次评，不自评；次评者已作答同题另一条件的暴露限制必须报告。