校准规则修订建议 v0.10

2026 年 10 月 24 日｜本轮 8 条输出已生成。这是预实验校准建议，不声称已在生成前冻结；正式规则须在正式输出产生前确认。保留 v0.9 草案、D 原意见、此次差异和最后确认版。

1. 保留 F 事实、E 引用、C 覆盖、B 边界四项 0—2 分。合格要求各适用项为 2 且无关键错误；关键错误先否决。无依据的重要断言由 B 及关键错误记录，不再让 C 另用五项二元标准覆盖 D 原表。

2. F/E 的 NA 逐项判断：回复确无事实断言或该项确不要求引用，才可填 NA，并写理由。题目“资料不足”不自动免于核验；回复若仍陈述事实、因果或声称证据缺失，就要检查相应断言。本轮两题有可答事实，不预设 NA。

3. 数字容差按答案明确表达的精度及预先约定的最低精度判断舍入区间，通常是半个显示单位，不统一放宽到±1 单位。约 8%与 8.10%可以是近似表达；8.00%是不同的精度声明。复杂计算和最低精度写进题目标准，不能看结果临时放宽。

4. 标准 U 只用于证据/时点/评价标准本身未决，不能用于模型自身的无依据回答。保留全部 N 个计划槽位和费用；若已知合格 P 条、未决 U 条，报告合格率范围[P/N,(P+U)/N]，并列 U/N 及已决子集 P/(N−U)。不能只报删去 U 后的比例。质量调整成本无法唯一确定时报告范围，零合格时不写 0 元。相同标准问题须一致处理受影响条件。

5. 技术失败、空输出在生产流程口径为不合格，内容维度留空并说明，不把无输出标为“没有事实错误”。截断但仍有内容时保留原文和状态，按约定评价实际内容；不能仅凭标签替代判断。本轮 8 次均有输出且 finish_reason=stop。

6. 过度拒答分母为存在可答核心的有效回复，必须指出遗漏的核心要点；全部不可答题不进入该分母。准确说明未知与回答可答部分可以同时发生，不能只看是否出现“无法回答”四个字。

7. 对 P-A07/P-A08 继续使用调用前 v0.8 已有核心。P-A08 包含类别平均收入的近似计算及其限制，不在看到输出后新增“必须并列外销、各品类原因”等要点；收入/销量均值不等同同款售价，不能证明具体经营因果。旧核心与 D 建议的差异留痕，未定项先标出、由 A/D 确认后再裁定。

8. A 和 D 各自保存讨论前评分；助手核查、自动解析均不算人类独立评分。D 七题事实提取不是八条输出评分。模型/流程映射仍只交 A/C；评分者如已看过映射、参考答案或另一人的评分，应记录暴露，不能追认完全盲评。

请在评分 Excel“08_规则确认”逐项填同意/修改及理由。第一版可按你明确填写的版本试评；有争议的项目保留意见，不假填团队已冻结。八条评分与七题事实修订应分开保存。